



iimas

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
INSTITUTO DE INVESTIGACIONES EN MATEMÁTICAS APLICADAS Y EN SISTEMAS

Media Catalog Intelligence: Pipeline de Calidad de Datos para la Integración de Metadatos Cinematográficos

Materia: Calidad y Preprocesamiento de Datos

Equipo:

Ashley Yael López Espinoza
Denzel Gael Cruz Prieto
Gustavo Mier Basilio
Pedro Manuel Cardón Carrillo
Salma Annette Rodríguez Muñoz

Ciudad Universitaria, CDMX
27 de Mayo de 2026

Índice

1. Introducción	3
2. Objetivos	3
3. Área de negocio	4
4. Problemática detectada	4
5. Preguntas de negocio	5
6. Propuesta de solución	6
6.1. Marco teórico de calidad de datos: TDQM	6
6.2. Dimensiones de calidad evaluadas	7
6.3. Herramientas	7
6.4. Descripción de las fuentes	8
6.5. Diagrama de integración	8
6.6. Modelo canónico	9
7. Desarrollo de la solución	10
7.1. Perfilado antes de la limpieza	10
7.1.1. Análisis cuantitativo de calidad por dimensión	10
7.1.2. Hallazgos cualitativos del campo <code>Run Time</code> de IMDb	12
7.1.3. Naturaleza de los nulos financieros en TMDb	12
7.2. Limpieza de datos	13
7.2.1. Funciones clave	13
7.2.2. Por qué no se imputaron <i>budget</i> ni <i>revenue</i>	14
7.3. Record linkage	14
7.3.1. Estrategias del <i>linkage</i>	14
7.3.2. Score compuesto de <i>linkage</i>	15
7.3.3. Clasificación y resolución <i>greedy</i> 1-a-1	15
7.3.4. Decisión metodológica central: solo <code>strong_match</code> fusiona	16
7.3.5. Ejemplos de <i>matches</i> reales y casos límite	16
7.3.6. Resultados del <i>linkage</i>	17
7.4. Obtención de datos maestros	19
7.4.1. Construcción del Golden Record	19
7.4.2. Reglas de supervivencia	19

7.4.3. Conflict flags	19
7.4.4. Data Quality Score	20
7.5. Detección de <i>outliers</i>	21
7.6. Perfilado posterior y comparación	23
7.6.1. Sobre el porcentaje global de nulos	24
8. Resultados	25
8.1. Resultados de las cinco problemáticas de negocio	25
8.1.1. P1 — Predicción de rentabilidad	25
8.1.2. P2 — Estimación de <i>revenue</i>	27
8.1.3. P3 — Sistema de recomendación basado en contenido	29
8.1.4. P4 — Ranking estratégico de géneros para inversión	29
8.1.5. P5 — Priorización de mercadotecnia	30
8.2. Consultas analíticas	31
8.2.1. Consultas sobre TMDb	31
8.2.2. Consultas sobre IMDb	33
8.2.3. Consultas integradas (TMDb + IMDb)	34
8.3. Resumen consolidado de resultados	40
9. Conclusiones de negocio	40
10. Conclusiones técnicas	41
11. Decisiones metodológicas, limitaciones y riesgos	42
11.1. Decisiones metodológicas críticas	42
11.2. Limitaciones del proyecto	43
11.3. Riesgos y restricciones	44
12. Trabajo futuro	44

1. Introducción

La industria audiovisual se sostiene cada vez más sobre datos. Plataformas de *streaming*, distribuidoras y estudios concentran decisiones financieras, editoriales y de mercadotecnia que dependen directamente de la calidad de los metadatos que describen su catálogo: títulos, fechas de estreno, géneros, duración, presupuesto, ingresos, ratings, productoras, elenco y dirección. Cuando esos metadatos provienen de fuentes distintas, la situación se complica: las fuentes utilizan identificadores propios, nombran a los campos de manera distinta, almacenan los mismos atributos con formatos heterogéneos, y casi nunca comparten un identificador común universal.

Este proyecto aborda ese problema concreto. Se trabaja con dos fuentes públicas que describen películas: **The Movie Database (TMDb)**, que aporta volumen y datos financieros y de popularidad para 946,460 títulos, e **IMDb**, representado por un subconjunto curado de 24,402 películas con metadatos editoriales ricos (sinopsis, director, elenco, palabras clave). El objetivo central no es solamente unir ambas fuentes, sino *integrarlas de forma defendible*: construir un catálogo maestro que pueda ser auditado, que conserve la trazabilidad del origen de cada dato, y cuyas decisiones de fusión, descarte e imputación estén explícitamente documentadas.

El reporte sigue una lógica narrativa que parte del problema de negocio, define una propuesta de solución bajo el marco TDQM (*Total Data Quality Management*), documenta el desarrollo técnico del *pipeline* y cierra con un análisis interpretativo de los resultados. La filosofía operativa que atraviesa todo el documento puede resumirse en una sola idea: *es preferible un dato faltante reconocido a un dato imputado silenciosamente*. Esta postura es especialmente importante en las variables financieras (presupuesto e ingresos), donde imputar valores sintéticos contaminaría las predicciones de rentabilidad, los rankings de inversión y la priorización de mercadotecnia.

2. Objetivos

Objetivo general

Construir un catálogo maestro de películas (**movie_master**) de alta calidad integrando TMDb e IMDb mediante un *pipeline* reproducible que aplique de manera ordenada perfilado, limpieza, *record linkage* probabilístico, fusión con reglas de supervivencia y auditoría posterior, todo bajo el marco TDQM.

Objetivos específicos

1. Identificar y documentar problemas de calidad de datos en cada fuente antes de cualquier intervención.
2. Implementar un *pipeline* modular de limpieza con funciones especializadas por tipo de campo: texto, fecha, duración, dinero, conteos y géneros.
3. Aplicar *record linkage* probabilístico entre TMDb e IMDb combinando coincidencia exacta, coincidencia con tolerancia de año ± 1 y *fuzzy matching* bloqueado.
4. Construir un *Golden Record* con reglas de supervivencia explícitas, trazabilidad de fuente (**source_trace**), *conflict flags* entre fuentes y un **data_quality_score** por registro.

5. Detectar valores atípicos univariados y multivariados sin eliminación automática.
6. Resolver cinco problemáticas de negocio: predicción de rentabilidad, estimación de *revenue*, recomendación basada en contenido, ranking estratégico de géneros para inversión y priorización de mercadotecnia.
7. Auditar formalmente el cumplimiento del proyecto y comparar la calidad de datos antes y después del *pipeline*.

3. Área de negocio

El área de negocio elegida es la **industria audiovisual con foco en *streaming* y distribución**. Aunque el proyecto puede aplicarse a un estudio cinematográfico, una distribuidora regional o un agregador de catálogo, el caso más representativo es el de una plataforma global de *streaming* que necesita un catálogo único y confiable para operar.

Esa plataforma toma decisiones en cinco frentes que dependen directamente de la calidad de los metadatos:

- **Recomendaciones personalizadas:** sin sinopsis, géneros y elenco limpios y consistentes, los algoritmos de recomendación generan sugerencias incoherentes.
- **Decisiones de adquisición e inversión:** sin métricas financieras confiables (*budget*, *revenue*, *profit*, ROI), los comités de inversión deciden sobre evidencia falsa.
- **Estrategia de mercadotecnia:** las campañas requieren combinar señales de calidad percibida (*ratings*) con señales de mercado (popularidad, votos) y proyecciones financieras.
- **Análisis de tendencias:** fechas de estreno correctas, géneros normalizados y métricas comparables entre décadas son la condición mínima para hablar de evolución del catálogo.
- **Reportes ejecutivos y auditoría:** cualquier indicador entregado a dirección debe ser reproducible y auditable; sin trazabilidad de fuente, no lo es.

4. Problemática detectada

Cuando se inspeccionan TMDb e IMDb por separado, ambas parecen razonablemente ordenadas. Cuando se intenta combinarlas, salen a la luz un conjunto de problemas que justifican el proyecto. Los problemas detectados en este *pipeline* se agrupan en seis categorías, todos cuantificados sobre los datos reales en la Sección 7.1.

Diferencias estructurales entre fuentes. TMDb e IMDb describen la misma entidad (la película) con esquemas distintos. TMDb usa la columna `title` con `release_date` en formato fecha completa, mientras que IMDb usa `movietitle` con `year` como entero. TMDb serializa los géneros en `genre_names` e IMDb en `genres` (con la errata ya presente en el dataset; Plot Keyword es análogo). TMDb es la única que aporta *budget*, *revenue*, *popularity* y *vote_count*; IMDb es la única que aporta *director*, *top5casts*, *overview* y *plotkeyword*. Ninguna comparte un identificador externo común.

Formatos heterogéneos dentro de un mismo campo. El campo `Run Time` de IMDb es el caso más severo: ningún valor está en formato puramente numérico. Aparecen duraciones en lenguaje natural ("1 hour 30 minutes", $n = 503$), pero también presupuestos disfrazados de duración (**4,394 filas con \$**, $\approx 18\%$ del dataset), marcadores de estado (**8,475 filas "not-released"**, $\approx 34.7\%$) y casos no clasificables. Solo aproximadamente la mitad de los registros tiene `runtime` reconstruible tras parseo robusto.

Patrones sistemáticos de captura inválida en IMDb. El campo `year` está almacenado como cadena de texto, no como entero. Más grave aún, **22,057 de 24,402 registros (90.4%) tienen el año almacenado con signo negativo** (p. ej. "2022" para una película de 2022). Lo mismo ocurre con `Rating`, almacenado como cadena con valores no numéricos como "no-rating" en 1,740 filas (7.1%). Estos no son errores aleatorios: son patrones sistemáticos del proceso de ingesta del dataset.

Problemas de completitud asimétricos entre fuentes. TMDb tiene completa la mayoría de sus campos estructurales (0 nulos en columnas pre-tipificadas), pero **571,153 registros (60.35%) tienen `vote_count` = 0**, lo que invalida el `vote_average` asociado: un *rating* promedio de 6.0 con cero votos no aporta información. Adicionalmente, **180,763 registros (19.10%) tienen `runtime` = 0**, claramente un marcador de ausencia. IMDb, en contraste, casi no tiene nulos formales (1% en *overview*), pero la mayor parte de sus campos numéricos está mal tipificada.

Duplicados intrafuente. TMDb contiene 24 `tmdb_id` duplicados que se eliminan en limpieza. IMDb, deduplicado por la clave compuesta `title_norm+release_year`, pierde 524 registros redundantes. En ambos casos los duplicados estaban ocultos detrás de variaciones de capitalización, acentos o años con signo invertido.

Ausencia de trazabilidad. Sin trazabilidad de origen, una vez fusionados los registros sería imposible reconstruir qué fuente aportó qué valor en cada campo. Esto rompe la auditabilidad y vuelve frágil cualquier decisión basada en el catálogo. El *pipeline* resuelve este punto con los campos `tmdb_id`, `imdb_path`, `source_count` y `source_trace`.

Anomalía financiera adicional. Tras parseo, **una fila de TMDb tiene `revenue` negativo (\$-12)**; el *pipeline* la invalida y queda contabilizada en los nulos del *Golden Record*.

5. Preguntas de negocio

Se identificaron cinco problemáticas concretas que el catálogo maestro debe habilitar resolver. Cada una está implementada en un bloque específico del notebook y se reporta en la Sección 8.

P1. Predicción de rentabilidad. ¿Es posible anticipar, dado el perfil de una película, si será rentable? Se aborda como un problema de clasificación binaria sobre `is_profitable` con *Logistic Regression* y *Random Forest*.

P2. Estimación de *revenue*. ¿Cuántos ingresos puede generar una producción? Se aborda como regresión sobre `log1p(revenue_usd)` con *Ridge* y *Random Forest Regressor*.

- P3. Sistema de recomendación.** ¿Qué películas recomendar a un usuario a partir de un título de referencia? Se implementa un recomendador basado en contenido con TF-IDF y `NearestNeighbors` con distancia coseno.
- P4. Ranking estratégico de géneros para inversión.** ¿En qué géneros conviene invertir o reforzar el catálogo? Se construye un `strategic_investment_score` compuesto por género.
- P5. Priorización de mercadotecnia.** ¿Qué títulos del catálogo deben recibir campaña? Se construye un `marketing_priority_score` por película.

6. Propuesta de solución

6.1 Marco teórico de calidad de datos: TDQM

Para abordar los problemas descritos en la Sección 4 se adoptó el marco **Total Data Quality Management (TDQM)** de Wang y Strong, que organiza la gestión de la calidad de datos como un ciclo iterativo de cuatro fases: *definir*, *medir*, *analizar* y *mejorar*. A esas cuatro fases este proyecto añade una fase explícita de *auditar*, que materializa la retroalimentación del ciclo y produce los artefactos de validación.

La elección de TDQM frente a otros marcos (DAMA-DMBOK, MD3M, DataOps) responde a tres criterios prácticos. Primero, TDQM está orientado a procesos y se adapta bien a *pipelines* programáticos: cada fase tiene entradas, salidas y métricas claras. Segundo, sus fases son lo suficientemente generales para cubrir tanto problemas intra-fuente (limpieza) como inter-fuente (integración). Tercero, el ciclo iterativo encaja con la realidad del proyecto: tras la primera vuelta del *pipeline* se detectaron problemas que llevaron a ajustes y nuevas iteraciones.

Definir. En esta fase se identifican las fuentes, la entidad común, las dimensiones de calidad relevantes y las reglas de negocio. Para este proyecto:

- *Fuentes:* TMDb (`movies.csv`) e IMDb (25k IMDb movie Dataset.csv).
- *Entidad común:* la película.
- *Dimensiones de calidad evaluadas:* completitud, validez, consistencia, unicidad, trazabilidad y exactitud operativa.
- *Reglas críticas:* no se imputará `budget_usd` ni `revenue_usd`; un valor cero en estos campos se interpretará como dato faltante; los *outliers* se marcarán con flags, no se eliminarán.

Medir. La fase de medición se materializa en el *perfilado inicial* (Bloque 1 del notebook). Para cada columna de ambas fuentes se calcula tipo de dato, número y porcentaje de nulos, número de valores únicos y una muestra de valores. Adicionalmente, se construyen diagnósticos específicos por fuente que buscan problemas conocidos del dominio: duplicados por título y año, runtime cero o fuera de rango, presupuestos negativos, *vote_average* fuera de [0, 10] y presencia de texto monetario en el campo runtime de IMDb.

Analizar. El análisis combina los resultados del perfilado con conocimiento de dominio. Las observaciones más relevantes (sintetizadas en la Sección 7.1) son: el campo `Run Time` de IMDb es semánticamente heterogéneo (mezcla duraciones, presupuestos y estados); el campo `year` de IMDb está almacenado como texto con signo negativo sistemático en el 90.4 % de los registros; un 60.35 % de los registros TMDb tienen `vote_count=0` (invalidando el *rating* asociado); y los nombres de columna no son consistentes entre fuentes (`Generes`, `Plot` `Kyeword`, capitalización mixta).

Mejorar. Se aplica un *pipeline* en cascada de limpieza intra-fuente, deduplicación, *record linkage* probabilístico, fusión con reglas de supervivencia y detección de *outliers* sin eliminación. Cada paso queda documentado, persistido en disco y validado por *assertions*.

Auditar. Se realiza un perfilado posterior comparable al inicial, se calculan tasas de fusión y se verifica el cumplimiento de cada requisito del proyecto mediante una lista de *checks* PASS/FAIL. Las 28 verificaciones implementadas pasaron exitosamente.

6.2 Dimensiones de calidad evaluadas

Tabla 1: Dimensiones de calidad evaluadas y su materialización en el *pipeline*.

Dimensión	Significado en este proyecto	Mecanismo
Compleitud	Ausencia de valores faltantes en campos críticos	Flags <code>_missing</code> ; <code>completeness_score</code>
Validez	Valores dentro de rangos y formatos esperados	Flags <code>_out_of_range</code> , <code>_parse_status</code>
Consistencia	Coherencia entre las dos fuentes para registros fusionados	<code>runtime_conflict</code> , <code>rating_conflict</code> , <code>genre_conflict</code> , <code>year_conflict</code>
Unicidad	Sin duplicados intra-fuente; <i>linkage</i> 1-a-1 inter-fuente	Deduplicación por <code>tmdb_id</code> y <code>title_norm+year</code> ; <i>greedy 1:1</i>
Trazabilidad	Capacidad de reconstruir el origen de cada dato	<code>tmdb_id</code> , <code>imdb_path</code> , <code>source_count</code> , <code>source_trace</code>
Exactitud op.	Métricas derivadas se calculan solo con datos observados	<code>profit_usd</code> , <code>roi</code> , <code>is_profitable</code> solo si <code>budget</code> y <code>revenue</code> reales

6.3 Herramientas

El *pipeline* está construido íntegramente en **Python 3**. Las librerías utilizadas son:

- **pandas**, **numpy**: manipulación de *dataframes* y operaciones numéricas.
- **matplotlib**: visualización de resultados.
- **rapidfuzz**: similitud difusa de cadenas (`token_set_ratio`, `token_sort_ratio`, `ratio`) para el *record linkage*.
- **scikit-learn**: `IsolationForest` para detección de *outliers* multivariados, `TfidfVectorizer` y `NearestNeighbors` para el recomendador, `LogisticRegression`, `RandomForestClassifier`, `Ridge` y `RandomForestRegressor` para los modelos predictivos, junto con `ColumnTransformer`, `Pipeline`, `StandardScaler` y `OneHotEncoder` para el preprocesamiento.


6.4 Descripción de las fuentes


TMDB — movies.csv. Catálogo principal de The Movie Database. Es la fuente más extensa del proyecto y la principal proveedora de datos financieros y de popularidad. Sus 946,460 registros cubren producciones desde inicios del siglo XX hasta estrenos recientes. Estructuralmente es una tabla bien formada: tipos de columna consistentes, identificador único por registro, y datos pre-tipificados. Sus principales debilidades son la presencia masiva de *budget* y *revenue* reportados como cero (que el *pipeline* interpreta como faltantes) y la cantidad de títulos sin votos en *vote_count*, lo que invalida su *vote_average* asociado.

IMDb — 25k IMDb movie Dataset.csv. Subconjunto curado de IMDb con 24,402 registros. Es estructuralmente más pequeño pero cualitativamente más rico en el plano editorial: aporta director, elenco principal (*top5casts*), sinopsis (*overview*) y palabras clave del argumento (*plotkeyword*). Sus problemas son más severos a nivel de captura: errores de tipeo en los nombres de columna (*Generes*, *Plot Keyword*), años con signo invertido, y el campo *Run Time* contaminado con presu-
puestos, *ratings* y marcadores de estado.

6.5 Diagrama de integración

La Figura 1 (presentada en texto por simplicidad) sintetiza la arquitectura del *pipeline*:



**Listing 1:** Arquitectura del pipeline (vista esquemática).

6.6 Modelo canónico

El modelo canónico de este proyecto se materializa en el *dataframe* `movie_master` y define cómo se nombran, tipan y pueblan los campos del catálogo maestro. No es una tabla aparte: es el esquema unificado del Golden Record. La Tabla 2 resume los campos más relevantes.

Tabla 2: Modelo canónico del catálogo maestro (`movie_master`).

Campo	Tipo	Descripción	Fuente preferida
<code>movie_master_id</code>	str	Identificador único del catálogo maestro (M_NNNNNNN)	Generado
<code>record_type</code>	str	<code>merged</code> , <code>tmdb_only</code> o <code>imdb_only</code>	Generado
<code>tmdb_id</code>	str	Identificador original TMDB	TMDB
<code>imdb_path</code>	str	Ruta original IMDb (/title/ttXXX/)	IMDb
<code>source_count</code>	int	Número de fuentes que aportan (1 o 2)	Generado
<code>source_trace</code>	str	<code>tmdb</code> , <code>imdb</code> o <code>tmdb imdb</code>	Generado
<code>title_display</code>	str	Título para mostrar al usuario	TMDB > IMDb
<code>title_norm</code>	str	Título normalizado (sin acentos, símbolos ni artículos)	Calculado
<code>release_year</code>	Int64	Año de estreno	TMDB > IMDb
<code>release_date</code>	datetime	Fecha completa	TMDB
<code>runtime_min</code>	float	Duración en minutos	TMDB > IMDb
<code>budget_usd</code>	float	Presupuesto (USD), 0 → NaN	TMDB
<code>revenue_usd</code>	float	Ingresos (USD), 0 → NaN	TMDB
<code>profit_usd</code>	float	<code>revenue</code> − <code>budget</code> , solo si ambos observados	Calculado
<code>roi</code>	float	<code>profit</code> / <code>budget</code> , solo si ambos observados	Calculado
<code>is_profitable</code>	float	1 si <code>revenue</code> > <code>budget</code> , 0 si no, NaN si faltan	Calculado
<code>vote_average_tmdb</code>	float	<code>Rating</code> TMDB; NaN si <code>vote_count</code> =0	TMDB
<code>vote_count_tmdb</code>	float	Conteo de votos TMDB	TMDB
<code>rating_imdb</code>	float	<code>Rating</code> IMDb (0-10)	IMDb
<code>user_rating_count_imdb</code>	float	Conteo de usuarios IMDb (parseado de "187K")	IMDb

Continuación de la Tabla 2

Campo	Tipo	Descripción	Fuente preferida
rating_normalized	float	<i>Rating</i> combinado ponderado por votos	Calculado
popularity_tmdb	float	<i>Score</i> de popularidad TMDB	TMDB
genres_list	list	Lista de géneros normalizados (unión TMDB $\cup$ IMDb)	Ambas
genres_canonical	str	Versión str de <code>genres_list</code>	Calculado
director, cast, overview, keywords	str	Datos editoriales	IMDb
linkage_score	float	<i>Score</i> del match (solo merged)	Generado
linkage_status	str	<code>strong_match</code> para todos los merged	Generado
data_quality_score	float	Score compuesto (0-1) por registro	Calculado
any_outlier_flag	bool	Cualquier flag IQR o multivariado	Calculado

La división de aportes por fuente es clara: TMDB aporta principalmente identificador, finanzas, popularidad, votos, productoras, idioma y país; IMDb aporta *rating* con conteo de usuarios, director, elenco, sinopsis y palabras clave. En los registros *merged*, ambas fuentes comparten título, año y duración, lo que además permite detectar conflictos entre fuentes.

7. Desarrollo de la solución

7.1 Perfilado antes de la limpieza

El perfilado inicial cuantifica los problemas descritos en la Sección 4 y establece la línea base contra la que se comparará el resultado del *pipeline*. TMDB se carga con 946,460 filas y 14 columnas; IMDb con 24,402 filas y 12 columnas (al añadir el indicador interno `_source`, las dimensiones reportadas por el *notebook* pasan a $946,460 \times 15$ y $24,402 \times 13$ respectivamente).

7.1.1. Análisis cuantitativo de calidad por dimensión

La Tabla 3 sintetiza los problemas detectados en cada fuente. Es importante separar conceptualmente dos tipos de ausencias: un *nulo estructural* ocurre cuando una fuente simplemente no provee ese atributo (los registros `tmdb_only` carecerán de `director` porque IMDb es la única fuente que lo aporta); un *nulo por captura* ocurre cuando el campo existe en el esquema pero el valor está ausente o codificado de forma inválida (un `vote_average` de 6.0 con `vote_count`=0 es operativamente equivalente a un dato no reportado). Confundir ambos lleva a decisiones incorrectas, típicamente imputación masiva que destruye la integridad analítica.

Tabla 3: Perfilado inicial: problemas detectados por fuente. Porcentajes sobre el total de filas de cada fuente.

Problema	TMDB ($n = 946,460$)		IMDb ($n = 24,402$)	
	N	%	N	%
<i>Compleitud</i>				
Títulos faltantes o vacíos	13,341	1.41	14	0.06
Año faltante o inválido	0	0.00	2,171	8.90
Año con signo negativo	—	—	22,057	90.39
(IMDb)				
<code>runtime</code> faltante o inválido	180,923	19.11	12,709	52.08
<code>vote_count</code> = 0 (rating no útil)	571,153	60.35	—	—
Rating no numérico ("no-rating")	—	—	1,682	6.89
<code>overview</code> nulo (IMDb)	—	—	244	1.00
<i>Validez (formatos)</i>				
<code>Run Time</code> en formato lenguaje natural	—	—	$\approx 11,169$	45.77
<code>Run Time</code> con \$ (presupuesto)	—	—	4,394	18.01
<code>Run Time</code> "not-released"	—	—	8,475	34.73
<code>revenue</code> negativo	1	0.0001	—	—
<i>Unicidad</i>				
Duplicados intrafuente (a eliminar)	24	0.003	524	2.15
<i>Trazabilidad inter-fuente</i>				
Identificador común a ambas fuentes		No existe		

La Figura 1 contrasta visualmente los porcentajes por fuente y permite ver el contraste estructural entre TMDB (problemas concentrados en *ratings* útiles) e IMDb (problemas concentrados en años y duraciones).




Figura 1: Perfilado inicial: porcentaje de registros con problemas en las dimensiones más críticas. TMDB e IMDb exhiben perfiles distintos: TMDB tiene un masivo 60 % de *ratings* no utilizables (`vote_count=0`), mientras que IMDb concentra sus defectos en años (90 % con signo invertido) y *runtime* (52 % inutilizable por formato).

7.1.2. Hallazgos cualitativos del campo Run Time de IMDb

El campo `Run Time` de IMDb es el caso más severo de heterogeneidad semántica del proyecto. La inspección de frecuencias revela tres regímenes operativos coexistiendo en el mismo campo:

- (I) **Duraciones genuinas en lenguaje natural:** la moda es "1 hour 30 minutes" (503 registros), seguida de "1 hour 35 minutes" (376), "1 hour 38 minutes" (350), etc.
- (II) **Presupuestos disfrazados de duración:** 4,394 filas contienen el símbolo \$, con patrones del tipo "\$170,000,000 (estimated)". Estos no son duraciones inválidas; son datos del campo equivocado.
- (III) **Estado de producción:** 8,475 filas contienen "not-released", indicando ausencia de duración por razones de la película misma, no del registro.

Esta tipología justifica el diseño del parser `parse_runtime` (Sección siguiente): no basta con descartar lo que no es entero; se necesita un código de estado (`runtime_parse_status`) que documente *por qué* se descartó cada valor, conservando así la trazabilidad de la limpieza.

7.1.3. Naturaleza de los nulos financieros en TMDB

El TMDB utilizado en este proyecto presenta una característica relevante: los campos `budget` y `revenue` *no contienen ceros* sino valores positivos en todas las filas (a excepción del único valor negativo \$-12 en `revenue`, que se invalida). Aun así, la función `parse_money` conserva su lógica `zero_as_missing` como salvaguarda metodológica, dado que en el dataset canónico de TMDB de Kaggle esos ceros sí aparecen y representan "dato no reportado" [16, 17]. La decisión de no imputar valores financieros se justifica por separado en la Sección 7.2.2.

7.2 Limpieza de datos

7.2.1. Funciones clave

La limpieza se construye sobre un conjunto de funciones especializadas por tipo de campo. A continuación se documentan únicamente las funciones y librerías *no convencionales*; las funciones triviales de *pandas* no se reproducen para no convertir este reporte en un manual.

Normalización de títulos. La función `normalize_title` construye una *clave técnica* para el *record linkage*; no reemplaza el título original. Reduce el texto a minúsculas, elimina acentos por descomposición Unicode (NFD), retira años entre paréntesis o sueltos, normaliza el carácter & a `.and`, elimina símbolos no alfanuméricos y suprime los artículos iniciales *the*, *a*, *an*.

```

1 def normalize_title(value):
2     if pd.isna(value):
3         return np.nan
4     value = str(value).strip().lower()
5     value = remove_accents(value)
6     value = re.sub(r"(\s*\d{4}\s*)", " ", value)
7     value = re.sub(r"\b\d{4}\b", " ", value)
8     value = value.replace("&", " and ")
9     value = re.sub(r"[^a-z0-9\s]", " ", value)
10    value = re.sub(r"\s+", " ", value).strip()
11    value = re.sub(r"^(the|a|an)\s+", "", value)
12    return value if value else np.nan

```

Listing 2: Función `normalize_title`, núcleo del *record linkage*.

Mini-ejemplo: "The Lord of the Rings: The Two Towers (2002)" se transforma en "lord of rings two towers", mientras que "Lord Of The Rings - Two Towers" produce exactamente la misma clave. Esa equivalencia es lo que habilita la primera capa de *matching* exacto.

Parser robusto de *runtime*. La función `parse_runtime` no solo intenta convertir a entero: clasifica los errores. Devuelve una tupla (`valor`, `status`) donde el `status` documenta por qué un valor fue rechazado: `money_in_runtime`, `not_released`, `too_small_probably_rating`, `unparsed`, etc. Esta clasificación se persiste en la columna `runtime_parse_status` y es esencial para diagnosticar la calidad del campo más problemático del proyecto.

Parser monetario. La función `parse_money` parsea valores en formato heterogéneo ("\$170,000,000 (estimated)", "1500000.0", etc.) eliminando símbolos y comas. Su decisión metodológica más importante es interpretar el cero como faltante (`zero_as_missing`): un presupuesto de cero dólares no significa que la película fuera gratuita, significa que el dato no fue reportado. Esta convención propaga la honestidad financiera a todo el *pipeline*.

Resultados de la limpieza. La Tabla 4 sintetiza el resultado de la limpieza intra-fuente. TMDb pierde 24 registros por deduplicación estricta por `tmdb_id`; IMDb pierde 524 por deduplicación sobre la clave `title_norm+release_year`, conservando el registro con mejor calidad (`rating`, `runtime` y `overview` presentes) cuando hay empates.

Tabla 4: Resumen de la limpieza intra-fuente.

Fuente	Filas <i>raw</i>	Filas <i>clean</i>	Eliminadas
TMDB	946,460	946,436	24
IMDb	24,402	23,878	524

7.2.2. Por qué no se imputaron *budget* ni *revenue*

Una alternativa común en *pipelines* de limpieza es imputar valores financieros (mediana, vecinos más cercanos, MICE). Este *pipeline* la rechaza deliberadamente. La razón es operativa: en el Bloque 11 se entrenan modelos de regresión y clasificación sobre `is_profitable` y `log1p(revenue_usd)`. Si `budget_usd` o `revenue_usd` estuvieran imputados, el modelo aprendería patrones del imputador y no del fenómeno real; el ranking de géneros del Bloque 13 reportaría rentabilidades artificiales basadas en mediana; el ranking de mercadotecnia del Bloque 14 priorizaría películas cuyas señales son sintéticas. La regla *exactitud operativa* > *completitud cosmética* es la columna vertebral metodológica del proyecto.

7.3 Record linkage

El *record linkage* es el corazón técnico del proyecto. Su objetivo es identificar pares (TMDB, IMDb) que representan la misma película pese a no compartir identificador. Un `merge` tradicional de `pandas` no es suficiente porque:

- Los identificadores no son comparables (`tmdb_id` numérico vs. `imdb_path`).
- Los títulos varían en mayúsculas, acentos, símbolos y artículos iniciales.
- Los años pueden diferir en uno (*premiere* mundial vs. local).
- La duración puede variar por cortes alternativos.
- Pueden existir homónimos en años cercanos que requieren desambiguación.

Por estas razones se implementó un *linkage* probabilístico en cascada con tres estrategias progresivamente más permisivas, cada una operando solo sobre los registros aún no enlazados por las anteriores.

7.3.1. Estrategias del *linkage*

Estrategia 1: *exact title* + *year*. Se hace un `merge` interno por la combinación `title_norm` + `release_year`. Esta capa captura 19,107 pares iniciales; tras resolución *greedy 1:1* y filtrado posterior a `strong_match`, quedan **18,575 matches** con `linkage_score`=100. Ejemplo: *Lock, Stock and Two Smoking Barrels* (1998) en ambas fuentes con título idéntico tras normalización.

Estrategia 2: *exact title* ±1 *year*. Para los IMDb aún no enlazados, se busca coincidencia exacta de título normalizado tolerando un desfase de un año (común porque TMDB usa fecha de estreno mundial mientras IMDb a veces registra el año de *premiere* local). Antes del filtrado a `strong` esta capa genera 1,195 candidatos; tras el filtrado quedan **732 matches** efectivos con `linkage_score` típicamente entre 92 y 95.

Estrategia 3: *fuzzy matching* bloqueado. Para los restantes 1,924 IMDb pendientes, se construye un índice de bloqueo (*blocking key*) por la combinación (primera letra del título normalizado, año). Para cada IMDb pendiente se evalúan únicamente candidatos del mismo bloque con año en $[\text{year} - 1, \text{year} + 1]$. Este bloqueo reduce la complejidad combinatoria de $\mathcal{O}(n \cdot m) \approx 22,000$ millones de comparaciones a unas decenas de miles [4, 5]. Para cada par candidato la similitud de título es

$$s_{\text{title}} = \max(\text{token_set_ratio}, \text{token_sort_ratio}, \text{ratio})$$

de **rapidfuzz** [7]. Antes del filtrado a **strong**, esta capa produce 1,063 matches; tras el filtrado quedan **555 matches** efectivos.

Por qué tres métricas y no una sola. **token_set_ratio** es robusto ante orden y duplicación de tokens (ej.: “Lord of the Rings, The” vs. “The Lord of the Rings”); **token_sort_ratio** captura permutaciones; **ratio** es la distancia de Levenshtein normalizada. Tomar el máximo evita penalizar coincidencias legítimas cuando una sola métrica falla.

7.3.2. Score compuesto de *linkage*

El **linkage_score** combina cuatro componentes con pesos normalizados por disponibilidad:

$$\text{linkage_score} = \frac{0.60 \cdot s_{\text{title}} + 0.25 \cdot s_{\text{year}} + 0.10 \cdot s_{\text{runtime}} + 0.05 \cdot s_{\text{genre}}}{\sum_i w_i \cdot \mathbb{I}[s_i \neq \text{NaN}]}$$

Tabla 5: Justificación de pesos en el score compuesto de *linkage*.

Componente	Peso	Justificación
Título (s_{title})	0.60	Es la señal más discriminativa: la probabilidad de que dos películas distintas tengan el mismo título normalizado y año es muy baja.
Año (s_{year})	0.25	Filtro temporal fuerte que desambigua remakes y homónimos. Función escalonada: 100 si $\Delta = 0$, 70 si $\Delta = 1$, 30 si $\Delta = 2$, 0 en otro caso.
Runtime (s_{runtime})	0.10	Útil pero presente solo en una fracción de los registros; función lineal por tramos sobre $ \Delta_{\text{runtime}} $.
Género (s_{genre})	0.05	Señal débil porque los géneros pueden diferir entre fuentes; Jaccard sobre conjuntos excluyendo Unknown .

Si alguno de los componentes es NaN (porque la información no existe en una de las fuentes), su peso se redistribuye proporcionalmente entre los disponibles. Esto evita penalizar registros por información que objetivamente no se puede comparar.

7.3.3. Clasificación y resolución *greedy* 1-a-1

El score se clasifica en cuatro categorías y la resolución 1-a-1 se aplica *después* de unir las tres pasadas:

- **strong_match**: **score** ≥ 90 . Se fusionan automáticamente en el *Golden Record*.

- **probable_match**: $82 \leq \text{score} < 90$. Se persisten en `record_linkage_probable_review.csv`, pero **no se fusionan**.
- **manual_review**: $75 \leq \text{score} < 82$. Se persisten en `record_linkage_manual_review.csv`, pero **no se fusionan**.
- **no_match**: $\text{score} < 75$. Se descartan completamente.

La resolución *greedy* ordena los matches por `linkage_score` descendente y aplica `drop_duplicates` primero por `tmdb_row_id` y luego por `imdb_row_id`. En conflictos, gana el match con mayor score. Esta heurística no garantiza el emparejamiento globalmente óptimo (que requeriría asignación bipartita *stable matching* o *Hungarian algorithm*), pero es computacionalmente tratable sobre $\sim 20,800$ candidatos y produce resultados conservadores: en caso de duda, prevalece la mayor evidencia.

7.3.4. Decisión metodológica central: solo `strong_match` fusiona

El *pipeline* adopta una regla explícita y conservadora: **solo los matches con estatus `strong_match` se fusionan automáticamente**. Los `probable_match` (733 registros) y `manual_review` (238 registros) se persisten en archivos separados para auditoría humana posterior, pero **no entran al Golden Record**. Esta política privilegia precisión sobre cobertura: una mala fusión contamina ratings, presupuestos, géneros, director y elenco, propagando el error a todos los análisis aguas abajo (modelos predictivos, ranking de géneros, recomendador, ranking de mercadotecnia). Es preferible dejar una película IMDb como `imdb_only` con información parcial pero correcta que mezclar atributos de películas distintas.

7.3.5. Ejemplos de *matches* reales y casos límite

La Tabla 6 muestra ejemplos representativos de cada estrato del `linkage_score`, extraídos sobre los datos reales del proyecto. Estos ejemplos permiten apreciar el tipo de decisiones que toma el algoritmo.

Tabla 6: Ejemplos reales de *matches* por nivel de *linkage_score*.

Nivel	Título TMDB	Título IMDb	Score
<i>strong_match</i> ($score \geq 90$, se fusionan)			
Idéntico	Lock, Stock and Two Smoking Barrels (1998)	Lock, Stock and Two Smoking Barrels (1998)	100
Idéntico	A Nightmare on Elm Street 3 (1987)	A Nightmare on Elm Street 3 (1987)	100
Idéntico	My Sister's Keeper (2009)	My Sister's Keeper (2009)	100
± 1 año	Omertà (2018)	Omerta (2017)	100
± 1 año	Wild Side (1996)	Wild Side (1995)	100
<i>Casos en frontera dentro de strong_match</i> (revisar manualmente sería deseable)			
Riesgo	Wicked (2024)	Wicked: Part Two (2025)	100
Riesgo	Maya (2020)	Maya the Bee 3: The Golden Orb (2021)	100
<i>probable_match</i> ($82 \leq score < 90$, no se fusionan)			
Variante regional	Harry Potter and the Philosopher's Stone (2001)	Harry Potter and the Sorcerer's Stone (2001)	86.2
Transliteración	Gatchaman (2013)	Gacchaman (2013)	88.9
Traducción	Theorem (1968)	Teorema (1968)	85.7
<i>manual_review</i> ($75 \leq score < 82$, no se fusionan)			
Secuela ambigua	Pushpa: The Rise (2021)	Pushpa: The Rule – Part 2 (2022)	80.0
Conflicto real	Fire Island (2019)	Freies Land (2019)	81.8
Diferente idioma	Çıldirtan Kadın (1978)	Çıldirtan kadin (1979)	80.0

Interpretación de los casos frontera. El ejemplo *Harry Potter and the Sorcerer's Stone/Philosopher's Stone* ilustra una limitación honesta del enfoque: son la **misma película** (título estadounidense vs. británico) pero el score de similitud de título queda en 86, por debajo del umbral **strong**. Sería un falso negativo del filtro: el sistema deja correctamente este caso para revisión humana. En contraste, *Wicked* (2024) y *Wicked: Part Two* (2025) son **películas distintas** (las dos partes de la adaptación) pero el score las clasifica como **strong_match**: un potencial falso positivo. Estos casos justifican la sección 11 sobre limitaciones del *pipeline*.

7.3.6. Resultados del *linkage*

La Tabla 7 sintetiza el resultado del *record linkage*. Es importante distinguir los conteos *antes* y *después* del filtrado a **strong_match**: la estrategia genera 20,833 candidatos totales, pero solo 19,862 entran al *Golden Record*.

Tabla 7: Resultados del *record linkage* probabilístico, antes y después del filtrado a **strong_match**.

Categoría	Generados	Usados (strong)
exact_title_year	18,575	18,575
exact_title_year_pm1	1,195	732
fuzzy_blocked	1,063	555
Total	20,833	19,862
<i>Distribución por estatus (sobre el total generado)</i>		
strong_match	19,862	—
probable_match	733	0 (no se fusionan)
manual_review	238	0 (no se fusionan)
Tasa de fusión sobre IMDb		83.18 %
Tasa de fusión sobre TMDB		2.10 %




Figura 2: Distribución del `linkage_score` entre los 19,862 *matches* usados para fusionar. La concentración masiva en `score = 100` corresponde a los *matches* por título y año exactos; las masas menores entre 90 y 100 corresponden a coincidencias con tolerancia de año o resueltas por *fuzzy matching*. Estadísticas: $\bar{x} = 99.57$, $\sigma = 1.80$, $\text{mín} = 90.00$, $Q_1 = Q_2 = Q_3 = 100$. El conjunto *merged* es altamente confiable.

Interpretación. El 83.18 % de los registros IMDb encontró contraparte en TMDB, lo cual es un nivel alto dado que las fuentes no comparten identificador y la coincidencia se reconstruye por similitud. La tasa baja de fusión sobre TMDB (2.10 %) no es una deficiencia del *linkage* sino una consecuencia matemática del tamaño relativo de los catálogos: con 946,436 registros TMDB limpios y solo 23,878 registros IMDb limpios, por construcción más del 97 % de los TMDB no pueden tener pareja en el subconjunto IMDb. El *ceiling* teórico de la tasa de fusión sobre TMDB es $23,878/946,436 \approx 2.52 \%$.

7.4 Obtención de datos maestros

7.4.1. Construcción del Golden Record

El Golden Record `movie_master` concatena tres tipos de registro mutuamente excluyentes:

- **merged** (19,862 registros): películas con *match strong*; datos combinados de TMDb e IMDb, trazabilidad completa y *conflict flags* activos.
- **tmdb_only** (926,574 registros): películas TMDb sin contraparte en IMDb; sin director, elenco, sinopsis ni *keywords*.
- **imdb_only** (4,016 registros): películas IMDb sin contraparte en TMDb; sin presupuesto, ingresos, popularidad ni votos.

La identidad de consistencia del catálogo se cumple exactamente:

$$\underbrace{950,452}_{\text{movie_master}} = \underbrace{946,436}_{\text{TMDb clean}} + \underbrace{23,878}_{\text{IMDb clean}} - \underbrace{19,862}_{\text{matches strong}}.$$

7.4.2. Reglas de supervivencia

Para los **merged**, cuando ambas fuentes aportan el mismo atributo, las reglas de supervivencia son las descritas en la Sección 6.6. Tres decisiones merecen destacarse:

- **title_display**: TMDb tiene prioridad porque suele contener el título oficial internacional, mientras que IMDb a veces conserva el título de *premiere* local.
- **genres_list**: se toma la **unión** de los géneros de ambas fuentes, no se elige una. Esto preserva información cuando las fuentes etiquetan distinto (por ejemplo, IMDb puede tener *Biographical* y TMDb *Drama, History*).
- **rating_normalized**: promedio ponderado de `vote_average_tmdb` y `rating_imdb` usando `vote_count_tmdb` y `user_rating_count_imdb` como pesos. Si solo una fuente aporta rating, se conserva ese.

7.4.3. Conflict flags

Cuando un registro **merged** tiene valores divergentes entre fuentes se activan flags específicos: **runtime_conflict** si la duración difiere por más de 10 minutos, **rating_conflict** si los *ratings* difieren por más de 2 puntos, **year_conflict** si los años difieren por más de uno, y **genre_conflict** si los conjuntos de géneros no comparten elementos. Estos flags *no descartan el registro*: lo marcan como inconsistente para que el **consistency_score** lo refleje. La decisión de aceptar o investigar queda en manos del consumidor del catálogo.

Observación empírica sobre los flags de conflicto. En el catálogo maestro resultante, los flags **runtime_conflict** y **year_conflict** están *a False* en todos los 19,862 **merged** (el perfilado posterior muestra una sola categoría única para esas columnas). Esto significa que para los *matches* aceptados como **strong**, las diferencias entre fuentes en estas dos dimensiones cayeron *por debajo*

de los umbrales de conflicto. El efecto principal de los flags se observa en las consultas integradas (Sección 8.2), donde se exploran los casos con mayor desacuerdo aunque no superen los umbrales: por ejemplo, la consulta INT Q4 identifica 25 películas con $|\Delta_{\text{runtime}}|$ entre 92 y 245 minutos. Esto muestra una limitación: **los umbrales actuales son conservadores y subdetectan los desacuerdos suaves**. Una revisión metodológica futura debería calibrarlos con muestreo humano (Sección 12).

7.4.4. Data Quality Score

A cada registro se le asigna un `data_quality_score` ($dqs \in [0, 1]$) combinando cinco dimensiones:

$$dqs = 0.35 \cdot s_{\text{comp}} + 0.25 \cdot s_{\text{val}} + 0.20 \cdot s_{\text{cons}} + 0.10 \cdot s_{\text{uniq}} + 0.10 \cdot s_{\text{trace}}.$$

Justificación de los pesos. La asignación no es arbitraria; refleja qué tipo de errores tendrían mayor impacto sobre los consumidores del catálogo en el caso de negocio (Sección 3):

Tabla 8: Justificación de los pesos del `data_quality_score`.

Dimensión	Peso	Razón
Compleitud (<code>comp</code>)	0.35	La carencia de campos clave (título, año, género, finanzas) hace al registro inutilizable para casi cualquier análisis (modelos, recomendador, rankings). Es el factor más limitante en el dominio cinematográfico.
Validez (<code>val</code>)	0.25	Valores fuera de rango (runtime negativo, rating > 10, budget negativo) producen análisis incorrectos sin avisar; el segundo factor más crítico.
Consistencia (<code>cons</code>)	0.20	Los conflictos inter-fuente señalan datos que pueden ser <i>ambos</i> legítimos (cortes alternativos) o uno incorrecto; afecta solo <code>merged</code> y debe penalizarse pero sin sobre-castigar.
Unicidad (<code>uniq</code>)	0.10	Importante a nivel agregado pero ya garantizada por la deduplicación intrafuente y la resolución <i>greedy</i> 1-a-1; en el catálogo final es prácticamente constante (=1).
Trazabilidad (<code>trace</code>)	0.10	Crítica para auditoría pero, por construcción, queda satisfecha en todos los registros (≥ 1 fuente con identificador).

Análisis de sensibilidad de los pesos. Si se redistribuyeran los pesos uniformemente (0.2, 0.2, 0.2, 0.2, 0.2), los `tmdb_only` subirían a ~ 0.93 y los `imdb_only` a ~ 0.89 , comprimiendo el ranking. La distribución actual exhibe la disponibilidad estructural de información de forma más fiel y discrimina mejor entre los tres tipos de registro.

Interpretación correcta del DQS. El `data_quality_score` es una **métrica operativa para comparar registros entre sí**, no una verdad absoluta. Un score alto significa que el registro tiene los campos esenciales presentes, en rangos válidos y sin conflictos detectados; no garantiza que los datos sean correctos en términos absolutos. Por construcción, los `merged` alcanzan los scores más altos (acceden a ambas fuentes), seguidos por `tmdb_only` y luego `imdb_only`; esto refleja la disponibilidad estructural de información en cada tipo de registro, no un defecto de los registros mono-fuente.

Tabla 9: Promedio de scores de calidad por tipo de registro (datos reales del catálogo maestro).

record_type	Compl.	Validez	Consist.	Trazab.	DQS
merged	0.9976	0.9961	0.9807	1.0000	0.9943
tmdb_only	0.8842	0.7894	1.0000	1.0000	0.9068
imdb_only	0.4984	0.9385	1.0000	1.0000	0.8091




Figura 3: Dimensiones de calidad por tipo de registro en el catálogo maestro. Se aprecia el efecto estructural: los `imdb_only` pierden completitud (0.50) por la ausencia de TMDB; los `tmdb_only` pierden validez (0.79) por los miles de `vote_count=0` y `runtime=0`; los `merged` dominan en todas las dimensiones simultáneamente.

7.5 Detección de *outliers*

La detección de *outliers* se aplica al catálogo maestro sobre seis variables relevantes (`runtime_min`, `budget_usd`, `revenue_usd`, `popularity_tmdb`, `vote_count_tmdb`, `roi`) usando dos métodos complementarios.

IQR univariado. La regla clásica $[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR]$ aplicada a cada variable produce flags binarios `{col}_outlier_iqr`. Es interpretable, no asume distribución y captura colas individuales.

Isolation Forest multivariado. Detecta combinaciones atípicas que pueden no ser *outliers* en ninguna variable individual. Se aplica con `contamination=0.03` sobre las variables transformadas con `log1p` para reducir el sesgo de cola.

Tabla 10: Resumen de *outliers* detectados por variable (IQR).

Variable	<i>Outliers</i>	% del catálogo
runtime_min	3,076	0.32 %
budget_usd	89,572	9.42 %
revenue_usd	108,962	11.46 %
popularity_tmdb	89,773	9.45 %
vote_count_tmdb	130,470	13.73 %
roi	94,080	9.90 %
Multivariado (Isolation Forest)	28,394	3.00 %
Cualquier flag (any_outlier_flag)	358,317	37.70 %

No se eliminan automáticamente. La decisión de marcar y no eliminar es deliberada y se fundamenta en tres razones operativas concretas. *Primero*, en cine un *outlier* financiero puede ser un error de captura (presupuesto reportado en moneda equivocada, runtime con un cero de más) o una superproducción real: distinguir una de otra requiere conocimiento de dominio, no estadística pura. *Segundo*, los análisis aguas abajo dependen explícitamente de esos casos atípicos: el ranking de mercadotecnia (Sección 8.1.5) y la consulta INT Q6 (Sección 8.2) buscan precisamente las películas de mayor *revenue*, y eliminarlas vaciaría el ranking. *Tercero*, los modelos predictivos (Sección 8.1.1) usan $\log_{10}(\text{revenue})$ como *target*; la transformación logarítmica ya atenúa el efecto de los extremos sin requerir eliminación.

Ejemplos reales de *outliers* financieros conservados. La Tabla 11 muestra los registros con mayor *revenue* del catálogo, todos clasificados como *outlier* por múltiples métricas. Son superproducciones legítimas que no deben eliminarse.


Tabla 11: Películas con mayor *revenue* en el catálogo. Todas están marcadas como *outliers* por las cuatro métricas (budget_outlier_iqr, revenue_outlier_iqr, roi_outlier_iqr, multivariate_outlier_iso).

Título	Año	Revenue (USD)	ROI
Avatar	2009	2.92 B	11.34
Avengers: Endgame	2019	2.80 B	6.86
Avatar: The Way of Water	2022	2.32 B	5.63
Titanic	1997	2.26 B	10.32
Ne Zha 2	2025	2.15 B	25.88
Star Wars: The Force Awakens	2015	2.07 B	7.44
Avengers: Infinity War	2018	2.05 B	5.84

Cómo se distribuyen los *outliers* entre tipos de registro. El cruce con *record_type* es informativo: de los 28,394 *outliers* multivariados detectados por Isolation Forest, 6,405 (22.6 %) corresponden a registros *merged* y 21,989 (77.4 %) a *tmdb_only*; en *imdb_only* no se detectan multivariados porque les faltan las dimensiones financieras necesarias para el algoritmo. Esto significa que los *outliers* se concentran en el subconjunto del catálogo con datos financieros observados, lo cual es esperable: solo donde hay datos puede haber valores extremos.

Implicación para los modelos. Las películas de la Tabla 11 participan en el conjunto de entrenamiento del modelo de *revenue* (Sección 8.1.2); su transformación logarítmica las mantiene en una

escala manejable y su presencia es fundamental para que el modelo aprenda el rango superior de la distribución. Si fueran excluidas, el modelo subestimaría sistemáticamente las predicciones de las películas de gran presupuesto, comprometiendo el ranking de mercadotecnia.




(a) $\log_{1p}(\text{budget})$ vs. $\log_{1p}(\text{revenue})$ con *outliers* multivariados en rojo. La nube principal se alinea con la diagonal (relación esperada). Los puntos rojos identifican combinaciones atípicas: películas con mucho *revenue* para poco *budget* (zona superior izquierda) o presupuesto sin retorno (zona inferior derecha).

(b) Distribución de ROI *winsorizada* visualmente al $[Q_1\%, Q_{99}\%]$ (solo para legibilidad de la gráfica; los valores extremos siguen presentes en los datos). Cola larga a la derecha consistente con películas de bajo presupuesto y alto *revenue*.


Figura 4: Diagnóstico de *outliers* en variables financieras.

7.6 Perfilado posterior y comparación


El perfilado posterior aplica la misma función `profile_dataframe` al catálogo maestro y produce `data_quality_report_after.csv`. La Figura 5 resume los tres hallazgos visuales más importantes.



(a) Distribución de `record_type`. El catálogo está dominado por `tmdb_only` (97.5%), lo cual es consecuencia del tamaño relativo de las fuentes, no de un defecto del *linkage*.



(b) `data_quality_score` por tipo de registro. Los `merged` concentran scores cerca de 1; los `tmdb_only` muestran mediana en 0.90; los `imdb_only` bajan a 0.80 por su menor completitud relativa.



(c) Porcentaje de nulos posteriores en columnas relevantes. La interpretación correcta es estructural: los campos `rating_imdb`, `overview`, `cast`, `director` e `imdb_path` tienen ~97% de nulos porque solo existen en registros con aporte de IMDb (los `merged` más los `imdb_only`, que juntos suman 23,878 sobre 950,452). No es un fallo del *pipeline*: es la consecuencia matemática del desbalance de tamaños entre fuentes.

Figura 5: Perfilado posterior del catálogo maestro.

7.6.1. Sobre el porcentaje global de nulos

La interpretación más delicada de este *pipeline* concierne a los nulos posteriores. Un lector apresurado podría concluir que el catálogo tiene mala calidad porque columnas como `rating_imdb` muestran 97% de nulos. **Esa interpretación es incorrecta.** El catálogo está dominado por `tmdb_only` simplemente porque TMDb es 40 veces más grande que el subconjunto IMDb usado. Por construcción, casi todos los registros del catálogo no tienen contraparte IMDb. Los campos exclusivos de IMDb (`director`, `cast`, `overview`, `rating_imdb`, `imdb_path`) son nulos en esos registros no porque la captura fuera defectuosa, sino porque *esa información literalmente no existe* para ellos. Confundir nulos estructurales con problemas de calidad lleva a soluciones equivocadas (típicamente, imputación masiva) que destruyen la integridad analítica.

La métrica honesta es *nulos por tipo de registro*: dentro de los 19,862 `merged`, el porcentaje de nulos en campos IMDb es prácticamente cero; dentro de los 4,016 `imdb_only`, el porcentaje de nulos en campos IMDb es también cercano a cero. El problema, por tanto, no es de calidad; es de cobertura, y la diferencia es esencial.

8. Resultados

8.1 Resultados de las cinco problemáticas de negocio

8.1.1. P1 — Predicción de rentabilidad

Definición del problema y target. La variable objetivo `is_profitable` es binaria: 1 si `revenue_usd > budget_usd` y 0 si no, con NaN cuando alguna de las dos no es observada. Esta definición sigue la regla metodológica de la Sección 7.2.2: el *target* solo existe para registros con datos financieros observados. Restringido a esos registros, el catálogo proporciona 946,435 muestras válidas, con una distribución {0 : 497,181 (52.53 %), 1 : 449,254 (47.47 %)}. El balance es lo suficientemente parejo para no requerir técnicas de re-muestreo.

Protocolo de evaluación. División estratificada 75/25 con semilla fija (`RANDOM_STATE=42`), produciendo:

- *Train set*: 709,826 registros.
- *Test set*: 236,609 registros, distribución {0 : 124,295, 1 : 112,314}.

La estratificación garantiza que la proporción de positivos se conserve en ambos conjuntos.

Prevención de fuga de información (*data leakage*). El *target* `is_profitable` se calcula como `revenue > budget`. Cualquier modelo que reciba como *feature* `revenue_usd`, `profit_usd` o `roi` aprendería trivialmente la definición y reportaría métricas artificialmente perfectas. Las tres variables se excluyen explícitamente del preprocesador. Esto deja a `log1p_budget` como única señal financiera disponible para predecir rentabilidad: el modelo debe inferir el `revenue` a partir del resto del perfil.

Variables predictoras. Tras la exclusión anterior, el modelo opera sobre 11 *features*:

Tabla 12: Variables predictoras de los modelos P1 (clasificación) y P2 (regresión).

Variable	Tipo	Preprocesador
log1p_budget	numérica	—
runtime_min	numérica	—
release_year	numérica	—
rating_normalized	numérica	—
log1p_popularity	numérica	—
log1p_vote_count	numérica	—
data_quality_score	numérica	—
source_count	numérica	—
original_language	categorica	OneHotEncoder
primary_genre	categorica	OneHotEncoder
record_type	categorica	OneHotEncoder


Justificación de los dos modelos. Se comparan dos algoritmos complementarios:

- *Logistic Regression*: línea base lineal interpretable. Coeficientes con significado directo, predicciones probabilísticas calibradas, sirve como “piso” de desempeño contra el cual contrastar modelos no lineales [12].
- *Random Forest Classifier*: ensamble de árboles que captura interacciones no lineales y discontinuidades sin requerir transformaciones (*e.g.*, el efecto del año no es lineal a lo largo del siglo). Robusto a *outliers*, no requiere escalado, maneja naturalmente la mezcla de *features* continuas y categóricas tras `OneHotEncoder`.

Resultados. La Tabla 13 presenta las métricas sobre el *test set*; la Figura 6 muestra matriz de confusión y curva ROC.

Tabla 13: Métricas de clasificación sobre el *test set* ($n = 236,609$).

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.730	0.734	0.676	0.704	0.817
Random Forest Classifier	0.898	0.904	0.878	0.891	0.959



(a) Matriz de confusión del *Random Forest* sobre el *test set*. TN: 113,845; FP: 10,450; FN: 13,675; TP: 98,639.

(b) Curva ROC del *Random Forest* sobre el *test set*. Área bajo la curva = 0.96.

Figura 6: Desempeño del modelo de clasificación de rentabilidad.

Interpretación de la diferencia entre modelos. La brecha entre *Logistic Regression* (AUC = 0.817) y *Random Forest* (AUC = 0.959) es significativa y consistente con la intuición del dominio: la rentabilidad cinematográfica depende de interacciones no lineales (un alto presupuesto solo es rentable en ciertos géneros y épocas; una popularidad alta solo importa por encima de un umbral mínimo de votos). El modelo lineal no puede capturar estas interacciones; el ensamble de árboles, sí. Por otro lado, que ambos modelos superen claramente el azar (AUC = 0.5) confirma que las *features* disponibles son informativas.

Justificación de las métricas reportadas. *Accuracy* es relevante porque las clases están balanceadas (no hay sesgo trivial por elegir la mayoría). *Precision* y *recall* se reportan porque el costo de un falso positivo (recomendar invertir en una película no rentable) es distinto al de un falso negativo (descartar una película rentable). *F1* resume el balance entre ambos. *ROC-AUC* es independiente del umbral de decisión y mide la capacidad de *ordenar* correctamente, que es lo que importa para los rankings de mercadotecnia y catálogo.

Aclaración honesta sobre el alcance del modelo. El modelo emplea variables como `rating_normalized`, `popularity_tmdb` y `vote_count_tmdb` que son posteriores al estreno. En consecuencia, *este modelo no es un predictor puro pre-estreno*: sirve para priorizar catálogo existente, evaluar la informatividad de las variables disponibles y servir como línea base para una versión futura restringida a variables pre-estreno (Sección 12).

8.1.2. P2 — Estimación de *revenue*

Target y motivación de la transformación logarítmica. La distribución de `revenue_usd` tiene cola extrema: el percentil 99 es de varios órdenes de magnitud mayor que la mediana (la

película de mayor revenue, *Avatar*, alcanza $2.92 \cdot 10^9$ USD contra una mediana del orden de $3 \cdot 10^6$). Modelar $\log_{1p}(\text{revenue_usd})$ estabiliza la varianza, hace que los residuos sean aproximadamente homoscedásticos y permite que modelos lineales (Ridge) sean comparables con no lineales (Random Forest). La función $\log_{1p}(\ln(1 + x))$ maneja el cero suavemente sin introducir indefiniciones.

Variables y prevención de *data leakage*. Las mismas *features* de la Tabla 12 excluyendo `revenue_usd`, `profit_usd`, `roi` e `is_profitable`.

Modelos comparados.

- *Ridge*: regresión lineal regularizada (L_2). Línea base interpretable. Su mejor desempeño se da cuando las relaciones son aproximadamente lineales en el espacio transformado por $\log_{1p}$.
- *Random Forest Regressor*: análogo al clasificador, captura no linealidades e interacciones.

Tabla 14: Métricas de regresión sobre el *test set* ($n = 236,609$).

Modelo	MAE (USD)	RMSE (USD)	$R^2_{\log}$	R^2_{orig}
Ridge	3.34 M	16.15 M	0.857	0.427
Random Forest Reg.	1.52 M	10.66 M	0.956	0.750




Figura 7: Revenue real vs. predicho en escala $\log_{1p}$ para el *Random Forest Regressor* sobre el *test set*. La nube se concentra fuertemente sobre la diagonal; la dispersión visible en la zona inferior corresponde a películas de bajo revenue con señales heterogéneas. La pendiente cercana a 1 indica buena calibración del modelo.

Resultados.

Interpretación de las dos métricas R^2 . El R^2 en escala logarítmica (0.956) refleja que el modelo ordena correctamente los títulos por magnitud de revenue, lo cual es lo relevante para el ranking de mercadotecnia. El R^2 en escala original (0.750) es menor porque las superproducciones extremas son difíciles de estimar con precisión absoluta: errar por \$50M en una película con revenue de \$2,000M es un error del 2.5 % en magnitud pero pesa fuerte en RMSE original. Para uso operativo de *ranking* (priorización de catálogo, mercadotecnia), la métrica relevante es la logarítmica; para reportes financieros absolutos, la original.

8.1.3. P3 — Sistema de recomendación basado en contenido

Se construyó un perfil textual por película concatenando título, géneros, director, elenco, *keywords*, *overview* y productoras tras limpieza ligera. Se aplicó `TfidfVectorizer` sobre el corpus y se entrenó un modelo `NearestNeighbors` con distancia coseno. Se trabajó sobre una muestra priorizada de 30,000 registros (los de mayor `rec_priority_score`, que combina `data_quality_score`, `source_count`, rating y popularidad).

Por qué *content-based*. El catálogo no contiene datos de actividad de usuarios, por lo que el filtrado colaborativo no es viable sin una fuente externa adicional. La ventaja específica del enfoque basado en contenido es que funciona en escenarios *cold-start*: usuarios nuevos sin historial, títulos recién agregados al catálogo y recomendaciones editoriales no personalizadas. La calidad de las recomendaciones depende directamente de la calidad textual del catálogo (sin géneros unificados ni sinopsis limpias, las recomendaciones son ruido), por lo que este bloque también funciona como prueba funcional de la calidad del catálogo maestro.

Ejemplo de salida: la consulta *Avatar* produce recomendaciones que incluyen *Avatar: The Way of Water*, *The Abyss* (mismo director, James Cameron), *Terminator 2: Judgment Day* (mismo director) y otros títulos del subgénero de ciencia ficción aventurera, lo cual sugiere que el perfil textual captura tanto similitud de género como de autoría.

8.1.4. P4 — Ranking estratégico de géneros para inversión

Se calculó un `strategic_investment_score` por género combinando tamaño de mercado, cobertura financiera, rentabilidad histórica observada, ROI mediano, *revenue* mediano, predicciones del modelo del Bloque 11, rating promedio, popularidad, actividad reciente, calidad promedio del dato y penalización por proporción de *outliers*. Cada componente se escala con min-max y se combina ponderadamente.




Figura 8: Ranking de géneros por `strategic_investment_score`. *Animation* lidera el ranking con 20.33, seguido de *Biographical* (17.63) y *Sport* (15.66). El score combina volumen, rentabilidad histórica, calidad del dato y predicciones del modelo del Bloque 11.

Interpretación honesta del ranking. Este ranking *no afirma que un género sea intrínsecamente mejor*. Lo que dice es: bajo los criterios definidos, estos géneros tienen el perfil más favorable para una decisión de inversión. Si los criterios cambiaran (priorizar nicho sobre masa, calidad crítica sobre éxito comercial), el ranking sería distinto. Es la traducción de una *estrategia explícita* en un orden, no un descubrimiento absoluto sobre la industria.

8.1.5. P5 — Priorización de mercadotecnia

Se construyó un `marketing_priority_score` por película que combina *revenue* predicho, probabilidad predicha de rentabilidad, `rating_normalized`, fortaleza estratégica del género (heredada del Bloque 13), brecha de visibilidad (rating alto con popularidad baja), `data_quality_score` y `source_count`.




Figura 9: Top 20 películas candidatas a recibir mayor inversión de mercadotecnia según `marketing_priority_score`. El ranking está dominado por animaciones de gran calidad editorial y comercial.

Lectura del ranking: por qué aparecen títulos clásicos. Si películas estrenadas hace una década o más aparecen entre las primeras posiciones, no significa que el ranking esté equivocado. Significa que esos títulos reúnen una combinación favorable de *rating* alto, género estratégicamente fuerte y datos de muy alta calidad, lo cual los convierte en candidatos legítimos para relanzamiento, curaduría temática, mantenimiento de visibilidad dentro del catálogo o ediciones especiales. El `marketing_priority_score` no es *qué estrenar*; es *en qué títulos del catálogo invertir esfuerzo de mercadotecnia dadas sus señales actuales*.

8.2 Consultas analíticas

El proyecto ejecuta dos lotes de consultas: cinco consultas por fuente (TMDB e IMDb) que demuestran que el catálogo maestro preserva la semántica original, y diez consultas integradas que combinan campos de ambas fuentes y solo son posibles gracias al *record linkage*. Esta sección presenta los resultados clave de cada consulta con interpretación de negocio.

8.2.1. Consultas sobre TMDB

TMDB Q1 — Top 10 películas por revenue observado. El liderazgo lo encabezan *Avatar* (\$2.92 B), *Avengers: Endgame* (\$2.80 B) y *Avatar: The Way of Water* (\$2.32 B). El *long tail* es

extremo: las 10 primeras superan los \$1.6 B mientras que la mediana del catálogo está en el orden de millones, lo cual confirma que las superproducciones son outliers legítimos del dominio (Figura 10). *Implicación*: cualquier modelo financiero debe respetar esta cola larga.




Figura 10: TMDB Q1 — Top 10 películas por revenue observado.

TMDB Q2 — Problemas financieros y outliers. El diagnóstico de calidad financiera sobre el catálogo da: `budget_was_zero = 0`, `revenue_was_zero = 0`, `revenue_missing = 1` (la fila con \$-12), `budget_outlier_iqr: 89,572 (9.46 %)`, `revenue_outlier_iqr: 108,962 (11.51 %)`, `roi_outlier_iqr: 94,080 (9.94 %)`, `multivariate_outlier_iso: 28,394 (3.00 %)`. *Implicación*: la mayoría de outliers no son errores sino películas extremas en cualquier dirección; el flag es informativo, no excluyente.

TMDB Q3 — Géneros más frecuentes. *Drama* (254,511 películas), *Documentary* (186,734), *Comedy* (151,522), *Animation* (61,894), *Horror* (59,873). La frecuencia bruta no equivale a relevancia comercial: el ranking estratégico (Sección 8.1.4) cruza esta señal con rentabilidad y predicciones.




Figura 11: TMDB Q3 — Géneros con mayor número de películas en el catálogo.

TMDB Q4 — Popularidad promedio por década. La popularidad media cae sostenidamente desde 1960 ($\bar{p} = 1.11$) hasta 2020 ($\bar{p} = 0.55$), lo que refleja el sesgo de selección de la métrica de TMDB (los clásicos consolidados acumulan popularidad a lo largo de décadas). *Implicación:* comparar popularidad cruda entre décadas distintas es engañoso; los modelos de mercadotecnia deben normalizar por época.

TMDB Q5 — Top 25 outliers financieros. Avatar, Avengers: Endgame, Avatar 2, Titanic, Ne Zha 2, Star Wars: TFA, Avengers: IW, Spider-Man: NWH, Inside Out 2, Jurassic World, The Lion King, The Avengers, Furious 7, Top Gun: Maverick, Frozen II. Las 25 películas tienen los tres flags IQR activos (*budget*, *revenue*, *roi*) y el flag multivariado de Isolation Forest. *Implicación:* todas son superproducciones legítimas; el flag confirma su carácter atípico sin sugerir descarte.

8.2.2. Consultas sobre IMDb

IMDb Q1 — Top 10 películas por rating IMDb. Los ratings más altos pertenecen a títulos de nicho con muy pocos votos: *Pinpoint* (9.9 con 25 votos), *The Memory Lane* (9.9 con 12 votos), *Vaaritha* (9.8 con 43 votos). *Implicación:* los ratings altos con bajo conteo de votos son estadísticamente frágiles; el ranking de mercadotecnia debe ponderar por confiabilidad (*user_rating_count_imdb*).

IMDb Q2 — Directores con mayor número de películas. Excluyendo el ruido “See company contact information” (137 filas, error de *scraping*), los más prolíficos son: *Woody Allen* (47), *Clint Eastwood* (38), *Alfred Hitchcock* (36), *John Ford* (32), *Steven Spielberg* (31), *Henry Hathaway* (31). *Implicación:* el dataset IMDb está sesgado hacia directores de renombre con carreras extensas, lo cual condiciona el alcance del recomendador basado en director.




Figura 12: IMDb Q2 — Directores con mayor número de películas en IMDb.

IMDb Q3 — Duración promedio por género. Los géneros con mayor duración promedio son *History* (121 min), *Biographical* (118 min) y *Musical* (117 min); los más cortos son *Fantasy* (100 min), *Western* (100 min) y *Comedy* (101 min). *Implicación:* el runtime puede usarse como rasgo informativo del género en clasificación/recomendación.

IMDb Q4 — Campos descriptivos faltantes. `director` y `cast`: 0 nulos; `overview`: 236 (0.99%); `rating_imdb`: 1,682 (7.04%); `runtime_min`: 2,892 (12.11%). *Implicación:* el subconjunto IMDb tiene completitud editorial muy alta, lo que lo hace ideal para el recomendador basado en contenido.

IMDb Q5 — Rating promedio por década. El rating IMDb medio decrece monotonamente desde la década de 1920 ($\bar{r} = 7.18$) hasta 2020 ($\bar{r} = 5.78$). *Implicación:* la audiencia contemporánea es más exigente o el dataset retiene solo los clásicos mejor evaluados de décadas tempranas (sesgo de supervivencia).

8.2.3. Consultas integradas (TMDB + IMDb)

Las 10 consultas integradas operan exclusivamente sobre los 19,862 registros `merged` (los únicos donde ambas fuentes coexisten) y demuestran el valor agregado del *record linkage*: ninguna podría responderse con una sola fuente.

INT Q1 — Películas con mayor confianza de fusión. Las 20 primeras tienen `linkage_score` = 100 por coincidencia exacta título+año. Casos como *Lock, Stock and Two Smoking Barrels* (1998) o *The Brothers Solomon* (2007) ilustran el caso ideal: título, año y duración alineados entre TMDB e IMDb. *Implicación:* estos registros son los más confiables para análisis cruzados.

INT Q2 — Títulos diferentes mismo año (matches por ± 1 año o fuzzy). 30 películas donde el título normalizado difiere pero el linkage los aceptó: *The Witches* vs. *Witches* (2020), *Aashiqui: True Love* vs. *Aashiqui - True Love* (2015), *Brahmastra Part One: Shiva* vs. *Brahmastra Part One: Shiva* (2022). *Implicación:* estos son los casos donde el *fuzzy matching* aportó valor genuino.




Figura 13: INT Q2 — Películas fusionadas con títulos distintos entre TMDB e IMDb.

INT Q3 — Mayor diferencia entre rating TMDB e IMDb. 25 películas con $|\Delta \text{rating}| \geq 5.5$. El caso extremo es *Troy: The Resurrection of Aeneas* (2018) con rating TMDB= 9.0 vs. IMDb= 1.1 ($\Delta = 7.9$). Estos desacuerdos coinciden con bajos conteos de votos en al menos una fuente: el rating TMDB de 9.0 proviene de *un solo voto*. *Implicación:* el rating combinado ponderado por conteo (*rating_normalized*) elimina la fragilidad estadística que un promedio simple no detectaría.




Figura 14: INT Q3 — Películas con mayor desacuerdo entre rating TMDB y rating IMDb.

INT Q4 — Conflictos de duración. 25 películas con $|\Delta\text{runtime}|$ entre 92 y 245 minutos. Ejemplos: *War and Peace* (1956) tiene 208 min en TMDB y 453 min en IMDb (corte completo vs. versión de cines, $\Delta = 245$); *The Perils of Pauline* (1914) tiene 410 vs. 199 min. *Implicación:* el campo runtime de IMDb (cuando es válido) suele referirse a la versión extendida o seriada; TMDB al corte teatral. Conviene preservar ambos en `runtime_tmdb` y `runtime_imdb` sin forzar resolución.

INT Q5 — Alto rating IMDb pero bajo revenue. 25 películas con rating IMDb ≥ 8.4 y revenue por debajo de \$2.5 M. Ejemplos: *The The* (2019, rating 9.7, ROI = -0.51), *Pathala Bhairavi* (1951, rating 8.4), *Modern Times* (1936, rating 8.5). *Implicación de negocio:* el catálogo contiene joyas críticamente aclamadas con bajo retorno comercial, candidatas naturales para curaduría editorial y restablecimiento de visibilidad.

INT Q6 — Alto revenue TMDB pero bajo rating IMDb. 25 películas con rating IMDb < 5.5 y revenue $> \$200$ M. El caso emblemático: la saga *Twilight* (*Breaking Dawn Part 1*: \$712 M con rating 4.9), *Fifty Shades of Grey* (\$570 M con rating 4.1), *Transformers: The Last Knight* (\$605 M con rating 5.2). *Implicación de negocio:* el mercado masivo no requiere alto rating crítico; estas franquicias son rentables a pesar de la baja recepción crítica.




Figura 15: INT Q6 — Películas con alto revenue pero bajo rating IMDb.

INT Q7 — Directores con mayor revenue promedio. Top 20 con datos cruzados (director de IMDb + revenue de TMDB): *Kyle Balda* (avg \$1.04 B con 3 películas), *Joss Whedon* (\$988 M, 3 películas), *Anthony Russo* (\$980 M, 7 películas), *James Cameron* (\$928 M, 7 películas). *Christopher Nolan* aparece con 11 películas, ROI promedio 3.23 y rating IMDb medio de 8.22 — el director más consistente en calidad y volumen. *Implicación:* este cruce es *imposible* con una sola fuente y es directamente accionable para decisiones de licenciamiento.




Figura 16: INT Q7 — Directores con mayor revenue promedio en películas fusionadas.

INT Q8 — ROI mediano por género. Géneros con mejor ROI mediano: *Film-Noir* (3.41), *Western* (1.30), *Documentary* (1.26), *Musical* (1.05). Los géneros de alto presupuesto (*Action*: 0.10, *Science Fiction*: 0.10) tienen ROI mediano bajo. *Implicación*: contradice la intuición de que las superproducciones de alto presupuesto son las más rentables en términos relativos; el ROI mediano premia a las producciones de bajo costo con buen rendimiento.

INT Q9 — Rentabilidad por década. La proporción de películas rentables varía dramáticamente: 1970s (92.8 %), 1960s (90.9 %), 1950s (82.6 %), 1940s (84.6 %) tienen las tasas más altas; 1990s (42.9 %) y 2020s (44.6 %) las más bajas. *Implicación*: la era pre-blockbuster tenía mejor rentabilidad relativa, posiblemente por presupuestos más conservadores y menor saturación del mercado.




Figura 17: INT Q9 — Tasa de rentabilidad por década.

INT Q10 — Alto potencial comercial sin desacuerdos entre fuentes. 25 películas con `commercial_potential_score` alto y los cuatro `conflict flags` en False: *Avatar*, *Avengers: Endgame*, *Avatar 2*, *Avengers: Infinity War*, *Spider-Man: NWH*, *Star Wars: TFA*, *Interstellar*, *The Dark Knight*, *Inception*. *Implicación:* la combinación de alto potencial comercial y cero conflictos inter-fuente identifica los registros más confiables del catálogo, ideales como “núcleo dorado” para mercadotecnia premium.

8.3 Resumen consolidado de resultados

Tabla 15: Métricas finales del proyecto.

Métrica	Valor
TMDB raw	946,460
IMDb raw	24,402
TMDB clean	946,436
IMDb clean	23,878
movie_master final	950,452
Registros merged	19,862
Registros tmdb_only	926,574
Registros imdb_only	4,016
Tasa de fusión sobre IMDb	83.18 %
Tasa de fusión sobre TMDB	2.10 %
data_quality_score promedio	0.908
data_quality_score mediano	0.900
Registros con al menos un flag de <i>outlier</i>	37.70 %
ROC-AUC clasificación rentabilidad (RF)	0.959
R^2 regresión revenue (RF, log)	0.956
Géneros evaluados para ranking	23
Candidatos a mercadotecnia	950,443
Auditoría final	28/28 PASS

9. Conclusiones de negocio

El catálogo maestro construido habilita decisiones de negocio sobre una base de datos verificable y auditable. Más allá del logro técnico, los resultados producidos por los cinco bloques analíticos arrojan implicaciones operativas concretas para una plataforma de *streaming* o distribuidora.

La integración inter-fuente produce valor que las fuentes aisladas no pueden producir.

Las 10 consultas integradas del Bloque 10 muestran que combinar campos financieros de TMDB con campos editoriales de IMDb permite responder preguntas estratégicas (qué directores generan mejor ROI, qué desfases hay entre rating crítico y popularidad) que ninguna fuente por separado podría contestar. La inversión en *record linkage* se justifica directamente por estos casos de uso.

La predicción de rentabilidad y revenue ya es operativa. Los modelos del Bloque 11 alcanzan AUC de 0.959 para clasificación y R^2 logarítmico de 0.956 para regresión. Aunque incluyen señales posteriores al estreno (rating, popularidad, votos), son inmediatamente útiles para ordenar el catálogo actual: identificar qué títulos del inventario tienen alta probabilidad de rentabilidad o alto revenue esperado alimenta decisiones de renovación de licencias, mercadotecnia y curaduría.

El ranking de géneros sintetiza una estrategia, no una verdad. El liderazgo de *Animation* (score 20.33), *Biographical* (17.63) y *Sport* (15.66) en el ranking refleja la combinación específica de criterios elegidos (rentabilidad histórica, cobertura financiera, calidad del dato, popularidad).

Cambiar los pesos o agregar criterios cambia el orden. Lo importante es que el método ofrece un mecanismo *reproducible* para traducir una política de inversión en una lista accionable.

El ranking de mercadotecnia identifica candidatos que un ranking ingenuo no detectaría.

Al usar revenue predicho en lugar de revenue histórico, el score destaca títulos cuyo potencial todavía no se ha materializado plenamente. La presencia de animaciones clásicas de alta calidad en el top sugiere que el catálogo dispone de activos infrautilizados que justifican campañas de relanzamiento o curaduría temática.

El recomendador basado en contenido cubre el escenario *cold-start*.

Sin necesidad de datos de usuarios, el sistema produce recomendaciones útiles para usuarios nuevos y para títulos recién agregados al catálogo. La consulta *Avatar* produce recomendaciones que combinan películas del mismo director (*The Abyss*, *Terminator 2*) y películas del mismo subgénero, lo cual es exactamente el comportamiento esperado de un sistema funcional.

Sin trazabilidad, las decisiones no son defendibles. Cada decisión del catálogo (qué fuente aportó qué valor, qué *matches* se aceptaron, qué *outliers* se marcaron, qué *conflicts* se detectaron) queda registrada. Un comité de inversión, una auditoría interna o un proceso regulatorio puede reconstruir el origen de cualquier indicador sin reabrir el *pipeline*.

10. Conclusiones técnicas

La identidad de consistencia se cumple exactamente.

$$950,452 = 946,436 + 23,878 - 19,862.$$

Esta verificación no es estética: es una invariante que descarta errores silenciosos de *double-counting* o pérdida de registros entre etapas. Que se cumpla con todos los conteos reales reportados confirma que la concatenación final preserva el universo de entrada.

El *record linkage* alcanzó 19,862 matches strong, equivalentes al 83.18 % de IMDb fusionado.

La cascada de tres estrategias (exact title+year $\rightarrow$ exact title ± 1 year $\rightarrow$ fuzzy bloqueado) demuestra ser una arquitectura sólida para problemas de integración inter-fuente sin identificador común. El 78.5 % del éxito proviene de la primera estrategia (matches exactos), confirmando la solidez de la normalización de títulos. La cobertura de fusión sobre TMDb (2.10 %) es baja por construcción matemática, no por deficiencia del *linkage*: TMDb es 40 veces más grande que el subconjunto IMDb utilizado.

La política “solo *strong_match* fusiona” protegió la integridad del Golden Record.

Los 733 *probable_match* y 238 *manual_review* se conservaron en archivos de evidencia pero *no se fusionaron*. Esta decisión privilegia precisión sobre cobertura y es coherente con el resto del *pipeline*.

La decisión de no imputar variables financieras protegió la integridad analítica.

budget_usd, *revenue_usd*, *profit_usd*, *roi* e *is_profitable* solo se calculan cuando *budget* y *revenue* reales están disponibles. Cualquier modelo o ranking que dependa de estas variables opera estrictamente sobre datos observados, no sobre valores sintéticos.

El *parser* robusto de runtime demostró su valor. El campo `Run Time` de IMDb contenía valores monetarios, *ratings* y marcadores de estado mezclados con duraciones reales. La trazabilidad mediante `runtime_parse_status` permite auditar cuántos registros se descartaron por cada motivo, en lugar de hacerlo silenciosamente.

La detección de *outliers* con flags (no eliminación) preservó las superproducciones legítimas. Las películas con *revenue* extremo (*Avatar*, *Endgame*, *Avatar 2*) son *outliers* estadísticos pero datos reales. Marcar y conservar permite que cada análisis decida si los incluye.

La auditoría final pasó las 28 verificaciones. El proyecto cumple formalmente todos los requisitos: dos fuentes integradas, perfilado inicial y posterior, limpieza por fuente, *record linkage*, Golden Record con tres tipos de registro, `data_quality_score`, detección de *outliers* sin eliminación automática, ausencia de imputación financiera, 5 consultas por fuente y 10 consultas integradas, modelos predictivos, recomendador, ranking de géneros y de mercadotecnia.

El *pipeline* es modular y reproducible. Cada bloque tiene entradas y salidas explícitas, persiste sus artefactos en `outputs/` y `figures/`, y queda validado por *assertions*. La semilla `RANDOM_STATE=42` fija el comportamiento aleatorio, y la ausencia de imputación silenciosa garantiza que ejecuciones repetidas produzcan idénticos resultados.

11. Decisiones metodológicas, limitaciones y riesgos

Esta sección consolida las decisiones de diseño que pueden cuestionarse, sus alternativas, y las limitaciones honestas del proyecto. La transparencia metodológica es parte del entregable.

11.1 Decisiones metodológicas críticas

1. Solo `strong_match` fusiona. La regla descarta 971 candidatos (733 `probable` + 238 `manual`) que *podrían* ser fusiones legítimas, como el ejemplo *Harry Potter Sorcerer's/Philosopher's* (Tabla 6). *Alternativa rechazada:* fusionar todos los `probable` (umbral ≥ 82). *Razón del rechazo:* una mala fusión propaga errores a *ratings*, finanzas, géneros, director y elenco simultáneamente; el costo de un falso positivo excede al beneficio marginal de cobertura adicional. *Trade-off explícito:* se sacrifica $\sim 4\%$ de cobertura adicional sobre IMDb por mantener precisión cercana al 100% en los registros `merged`.

2. `zero_as_missing` en `budget` y `revenue`. La función `parse_money` interpreta 0 como NaN. *En este CSV particular* esa lógica no se activa porque los valores son positivos en todas las filas (Sección 7.1), pero la convención se conserva por estabilidad metodológica: si el *pipeline* se ejecutara sobre el TMDb canónico de Kaggle (donde $\sim 95\%$ de `budget` es 0), el comportamiento sería el correcto.

3. No se imputan variables financieras (Sección 7.2.2). La regla *exactitud operativa* $>$ *completitud cosmética* es inviolable. *Alternativa rechazada:* imputar por mediana de género o por KNN. *Razón:* cualquier valor sintético introducido por el imputador contaminaría los modelos predictivos

del Bloque 11, los rankings de los Bloques 13 y 14, y haría que los reportes financieros del catálogo perdieran su carácter auditable.

4. Outliers como flags, no eliminación (Sección 11). *Alternativa rechazada:* eliminar registros con `any_outlier_flag = True`. *Razón:* eliminaría 358,317 registros (37.70 % del catálogo), incluyendo todas las superproducciones que son objetivo principal de los rankings de mercadotecnia.

5. TMDB tiene prioridad para título e IMDb para director. *Razón:* TMDB tiende a contener el título oficial internacional; IMDb, con su énfasis en metadatos editoriales, conserva el director con menor proporción de errores que TMDB en este subconjunto. Es una heurística de dominio, no una verdad universal.

6. Bloqueo *first_letter + year* en el fuzzy matching. Reduce 22 mil millones de comparaciones a unas decenas de miles. *Limitación:* títulos que difieren en su primera letra (*p. ej. The Witches* vs. *A Witch's Tale*) no se evalúan, generando falsos negativos del *linkage*. Una variante con bloqueo por hash de tokens podría capturarlos a costo computacional moderado.

11.2 Limitaciones del proyecto

Asimetría estructural de las fuentes. TMDB tiene 40 veces más registros que el subconjunto IMDb utilizado (946,436 vs. 23,878). La tasa máxima teórica de fusión sobre TMDB es $23,878/946,436 \approx 2.52\%$; el proyecto alcanza 2.10 %, equivalente al 83.4 % del techo teórico. *Consecuencia:* el catálogo está estructuralmente dominado por `tmdb_only`, lo cual hace que cualquier análisis que requiera información editorial (director, cast, overview) opere sobre solo un 2.5 % del catálogo total. Cualquier conclusión sobre “el catálogo” debe leerse con esta restricción presente.

Falsos positivos del *strong_match*. Ejemplos como *Wicked* (2024) vs. *Wicked: Part Two* (2025), o *Maya* (2020) vs. *Maya the Bee 3: The Golden Orb* (2021), reciben `linkage_score=100` por coincidencia exacta de título normalizado en bloque, aunque son películas distintas. La inspección manual sugiere que estos casos son menos del 1 % de los `strong_match`, pero el número exacto no está cuantificado en este proyecto.

Falsos negativos no cuantificados. El caso *Harry Potter Sorcerer's/Philosopher's Stone* ejemplifica matches legítimos clasificados como `probable_match`. Una muestra estratificada de los 971 descartados, evaluada manualmente, daría una estimación de recall del *linkage*, pero no se realizó.

Umbrales de *conflict flags* demasiado conservadores. `runtime_conflict` requiere $|\Delta| > 10$ min y `rating_conflict` requiere $|\Delta| > 2$ puntos. En los 19,862 `merged` todos los flags terminan en False, pese a que la consulta INT Q4 muestra discrepancias de hasta 245 min. Una calibración más sensible mejoraría la utilidad del `consistency_score`.

Modelos no son pre-estreno puros. `rating_normalized`, `popularity_tmdb` y `vote_count_tmdb` se conocen después del lanzamiento. Los AUC y R^2 reportados no son extrapolables a la predicción de una película sin estrenar. El modelo es operativo para *priorización de catálogo existente*, no para luz verde a un proyecto en *development*.

Datos financieros no son verdad de mercado contrastada. Los valores de `budget` y `revenue` en este TMDb son sintéticos (decimales como 2426.70), no las cifras reales reportadas por la industria. Las cantidades absolutas de los modelos y rankings deben tomarse como relativas dentro del catálogo, no como pronósticos en USD reales.

Sesgo de selección del dataset IMDb. El subconjunto de 24K películas no es una muestra aleatoria de IMDb; sobre-representa películas con presencia comercial occidental y con popularidad suficiente para haber sido scrapeadas. El recomendador y los rankings de director heredan este sesgo.

Ausencia de datos de usuario. El recomendador es estrictamente *content-based*; no incorpora señales de comportamiento (visualizaciones, completion rate, ratings personales). La calidad de las recomendaciones se evalúa por inspección cualitativa, no por métricas como NDCG@K sobre datos de interacción.

11.3 Riesgos y restricciones

Riesgo de *data leakage* en producción. Los modelos fueron entrenados con *split* aleatorio estratificado. Si se desplegaran en producción, un *split* temporal (entrenar hasta año T , evaluar año $T + 1$) sería más conservador y probablemente reduciría el AUC reportado. Las métricas actuales son optimistas para uso predictivo en horizonte temporal.

Riesgo de obsolescencia de las normalizaciones. El `GENRE_MAP`, los umbrales de `parse_runtime` y los patrones de `parse_money` están *hardcoded*. Nuevos formatos de datos o nuevos géneros (formatos de *streaming* cortos, contenido interactivo) requerirían actualización manual. No hay mecanismo de detección automática de drift de esquema.

Restricción de escalabilidad. El *record linkage* actual procesa $\sim 24K \times 946K$ en minutos en un solo nodo. Para conjuntos de varios millones $\times$ millones sería necesario un motor distribuido (Splink, Dedoop, o servicios MDM dedicados).

Restricción legal y de licencia. El proyecto utiliza datos públicos de TMDb [16] e IMDb [18]. Su uso comercial está sujeto a los términos de cada API/dataset; un despliegue real requeriría revisión de licencia.

12. Trabajo futuro

Enriquecimiento con identificadores externos. La API oficial de TMDb expone el `imdb_id` de cada película. Descargarlo permitiría record linkage por identificador exacto, llevando los `probable_match` y `manual_review` al catálogo con certeza, sin sacrificar precisión.

Versión pre-estreno de los modelos predictivos. Restringir las *features* a variables disponibles antes del lanzamiento (género, runtime, director, productora, budget, idioma, época, equipo creativo) y reportar métricas sobre ese conjunto. El resultado tendría más fricción operativa pero respondería literalmente la pregunta “¿será rentable esta producción?”.

Ajuste por inflación. Incorporar índice CPI por año y producir `budget_usd_real` y `revenue_usd_real` ajustados, permitiendo comparaciones financieras válidas entre décadas y rankings de géneros normalizados temporalmente.

Recomendador híbrido. Cuando se disponga de datos de actividad de usuarios (visualizaciones, ratings, listas), combinar el *content-based* actual con filtrado colaborativo. El *content-based* permanecería como respaldo para *cold-start*.

NLP sobre overview y keywords. Aplicar extracción de tópicos (LDA, BERTopic), análisis de sentimiento de la sinopsis y *embeddings* semánticos (*sentence-transformers*) para enriquecer el perfil del recomendador y crear nuevas *features* para los modelos.

Pipeline incremental. Convertirlo en un proceso que ingiera nuevos títulos de forma incremental (Airflow, Prefect) en lugar de procesar todo desde cero. Esto implica adaptar el *record linkage* para evaluar solo registros nuevos contra el catálogo existente.

Validación humana muestral del *linkage*. Tomar una muestra estratificada por rango de `linkage_score` y validarla manualmente para estimar precisión y recall reales. Permitiría calibrar los umbrales `strong/probable/manual` con evidencia, no con intuición.

Dashboard interactivo. Desplegar las visualizaciones y el motor de recomendación como una aplicación (Streamlit, Dash) que permita a analistas no técnicos explorar el catálogo, simular cambios en los pesos del *strategic investment score* y descargar listas filtradas.

Reglas de calidad en tiempo real. Implementar validaciones automatizadas (Great Expectations, Pandera) que evalúen nuevos registros contra los rangos y patrones aprendidos del catálogo actual, alertando cuando un nuevo registro rompe la distribución esperada.

Referencias

- [1] Wang, R. Y., & Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4), 5–33.
- [2] Wang, R. Y. (1998). A product perspective on total data quality management. *Communications of the ACM*, 41(2), 58–65.
- [3] DAMA International. (2017). *DAMA-DMBOK: Data Management Body of Knowledge* (2nd ed.). Technics Publications.
- [4] Fellegi, I. P., & Sunter, A. B. (1969). A theory for record linkage. *Journal of the American Statistical Association*, 64(328), 1183–1210.
- [5] Christen, P. (2012). *Data Matching: Concepts and Techniques for Record Linkage, Entity Resolution, and Duplicate Detection*. Springer.

- [6] Winkler, W. E. (2006). Overview of record linkage and current research directions. *Statistical Research Division, U.S. Census Bureau, Research Report Series*.
- [7] Bachmann, M. (2023). RapidFuzz: Rapid fuzzy string matching in Python and C++. <https://github.com/maxbachmann/RapidFuzz>.
- [8] Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008). Isolation forest. In *2008 Eighth IEEE International Conference on Data Mining* (pp. 413–422). IEEE.
- [9] Liu, F. T., Ting, K. M., & Zhou, Z. H. (2012). Isolation-based anomaly detection. *ACM Transactions on Knowledge Discovery from Data*, 6(1), 1–39.
- [10] Spärck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, 28(1), 11–21.
- [11] Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523.
- [12] Pedregosa, F., Varoquaux, G., Gramfort, A., *et al.* (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [13] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- [14] McKinney, W. (2010). Data structures for statistical computing in Python. In *Proceedings of the 9th Python in Science Conference*, 445, 51–56.
- [15] The Movie Database. (2024). TMDb API documentation. <https://developers.themoviedb.org/>.
- [16] TMDb Movies Dataset. (2024). Kaggle dataset (versión usada en este proyecto: `movies.csv`). <https://www.kaggle.com/datasets>.
- [17] Banik, R. (2017). The Movies Dataset (TMDb metadata). Kaggle. <https://www.kaggle.com/datasets/rounakbanik/the-movies-dataset>.
- [18] IMDb 25k Movie Dataset. (2024). Kaggle dataset (versión usada en este proyecto: `25k IMDb movie Dataset.csv`). <https://www.kaggle.com/datasets>.
- [19] Internet Movie Database. (2024). IMDb non-commercial datasets. <https://datasets.imdbws.com/>.
- [20] Redman, T. C. (2008). *Data Driven: Profiting from Your Most Important Business Asset*. Harvard Business Press.
- [21] Batini, C., Cappiello, C., Francalanci, C., & Maurino, A. (2009). Methodologies for data quality assessment and improvement. *ACM Computing Surveys*, 41(3), 1–52.